

17기 정규세션

ToBig's 16기강의자  
이예림

# Time Series Analysis

시계열분석

# Contents

---

Unit 01 | 시계열 데이터

---

Unit 02 | 고전적 분석 - 평활법 & 분해법

---

Unit 03 | 확률적 분석 - AR, MA, ARMA

---

Unit 04 | Box-Jenkins 방법론

---

# Contents

---

Unit 01 | 시계열 데이터

---

Unit 02 | 고전적 분석 - 평활법 & 분해법

---

Unit 03 | 확률적 분석 - AR, MA, ARMA

---

Unit 04 | Box-Jenkins 방법론


---

## Unit 01 | 시계열 데이터


# 시계열 데이터 (Time Series Data)

- **시간의 흐름에 따라** 일정한 간격으로 기록된 종단면 데이터
  - Ex. 주가지수, 일일 기온, 월별 교통사고 건수, 연간 광고 비용 등

시계열 데이터 예시



(참고) 횡단면 데이터 VS 종단면 데이터



\* V1, V2, V3 V4는 각각 다른 변수

\* T1, T2, T3, T4는 각각 다른 시점

## Unit 01 | 시계열 데이터

# 시계열의 구성

### 추세 (Trend)

- 시계열의 장기적 경향
- 상승 경향 or 감소 경향  
or 안정적

### 계절성 (Seasonal Variation)

- 1년 주기
- 단기적 변동
- Ex. 여름에는 냉방기기  
판매량이 높고, 겨울에는  
판매량이 낮음

### 순환 (Cycle Variation)

- 1년보다 긴 주기(2년  
~10년)를 갖고 순환
- 중기적 변동
- Business Cycle


### 불규칙 요인 (Irregular Movements)

- 예측 및 제어가 불가능
- 우연적
- Noise

## Unit 01 | 시계열 데이터

# 시계열 모형화

- 시계열을 구성하는 4가지 요소는 단일로 시계열을 구성하기도, 가법 or 승법으로 구성하기도 한다.
- **가법 모형 (Additive Model)**
  - 구성요소 간 **독립**을 가정
  - 각 구성요소를 **더하는** 모형
- **승법 모형 (Multiple Model)**
  - 구성요소 간 **상호작용**을 가정 (독립 X)
  - 각 구성요소를 **곱하는** 모형
- 시계열 분해 : 하나의 시계열을 구성요소별로 분해



## Unit 01 | 시계열 데이터

# 시계열 분석 목적

### 기술

- 시도표(time plot)나 자기상관함수를 사용해 자료의 특성 파악
- 추세, 계절성, 특이점, 변화점 등을 파악

### 예측

- 시계열 분석의 가장 중요한 목적
- 특정 데이터가 과거 변화 패턴과 비슷하게 현재 시점 이후에도 변화할 것이라는 전제 하에, 미래의 값을 예측

### 설명

- 특정 시스템의 시계열적 패턴을 설명하기 위한 과학적 노력
- Ex. 경제 시계열 분석을 통해 경기 주기가 존재함을 입증

### 제어

- 특정 시스템에 인위적인 조작을 가해 원하는 목표에 부응하도록 유도
- Ex. 극심한 경기 변동이 우려되는 경우, 정부가 중앙은행을 통해 정책적으로 개입

# Contents

---

Unit 01 | 시계열 데이터

---

Unit 02 | 고전적 분석 - 평활법 & 분해법

---

Unit 03 | 확률적 분석 - AR, MA, ARMA

---

Unit 04 | Box-Jenkins 방법론

---



## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 평활법 (Smoothing Method)

- **평활법** : 과거 및 현재 데이터의 불규칙 변동을 부드럽게 평활(smoothing)하여 미래 값 예측
- **평활법의 종류**
  - **목측법(Eye-measurement)** : 눈짐작으로 선 긋기. 정확성은 낮으나 신속한 경향 파악 가능.
  - **이동평균법(Moving Average Method)** : 최근 특정 기간의 관측치 몇 개를 **산술평균**한 값을 이용해 미래 시점의 예측치로 사용
  - **지수평활법(Exponential Smoothing)** : 모든 데이터를 활용하되, 최근 관측치에 더 큰 가중치를 준 **가중평균** 값을 미래 시점의 예측치로 사용
  - **최소제곱법** : 편차의 제곱합을 최소화 하는 경향선을 구해 미래 값 예측 (회귀분석)

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 이동평균법 (1) - 단순 이동평균법

- 이동평균법 : 최근 특정 기간의 관측치 몇 개를 산술평균한 값을 이용해 미래 시점의 예측치로 사용
- **단순 이동평균법** : 가장 최근에 얻어진 관측값  $m$ 개의 산술평균값을 이용
  - 시계열  $\{Z_n\}$ 에서, 시점  $t$ 에서의 관측값을  $Z_t$  라 할 때, 시점  $n$ 에서의 단순 이동평균

$$: MA_n = \frac{Z_n + Z_{n-1} + \cdots + Z_{n-m+1}}{m} = \frac{1}{m} \sum_{t=n-m+1}^n Z_t$$

- 시점  $n$ 에서 추정한 시점  $n+1$ 의 예측값을  $F_{n+1}$  이라고 하면,  $F_{n+1} = MA_n$


## Unit 02 | 고전적 분석 - 평활법 & 분해법

### 이동평균법 (1) - 단순 이동평균법

Week	Demand	3-week MA	6-week MA
1	650		
2	678		
3	720		
4	785	683	
5	859	728	
6	920	788	
7	850	855	769
8	758	876	802
9	892	843	815
10	920	833	844
11	789	857	867
12	844	867	855

$$= (650+678+720)/3$$

$$= (650+678+720+785+859+920)/6$$



- 데이터 변동이 클수록, 최근 데이터의 경향을 많이 반영해야 함  
→ **m이 작아야** 함
- 데이터의 변동이 완만하다면,  
→ m이 커도 됨
- m의 선택 : MSE를 최소로 하는 m

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 이동평균법 (2) – 이중(선형) 이동평균법

- 선형 추세가 있는 시계열에 단순 이동평균법을 적용하면, 추세를 늦게 따라가는 문제 발생
- **이중(선형) 이동평균법** : 이동평균을 두 번 적용한 방법

- 시계열  $\{Z_n\}$ 에서, 시점  $t$ 에서의 관측값을  $Z_t$  라 할 때, 시점  $n$ 에서의 **단순 이동평균**

$$: MA_n = \frac{Z_n + Z_{n-1} + \cdots + Z_{n-m+1}}{m} = \frac{1}{m} \sum_{t=n-m+1}^n Z_t$$

- 시계열  $\{Z_n\}$ 에서, 시점  $t$ 에서의 관측값을  $Z_t$  라 할 때, 시점  $n$ 에서의 **이중(선형) 이동평균**

$$: MA'_n = \frac{1}{m} (MA_n + MA_{n-1} + \cdots + MA_{n-m+1})$$

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 이동평균법 (2) - 이중(선형) 이동평균법

## 참고) 이동평균 계산

시계열  $\{Z_t\}$ 이 다음과 같은 선형추세를 갖는다고 할 때

$$Z_t = a + bt + e_t$$

- 시점  $t$ 에서의 한 단계 이후  $t+1$  시점의 예측치

$$F_{t+1} = E[Z_{t+1} | Z_t, Z_{t-1}, \dots, Z_1] = a + b(t+1)$$

$$\widehat{F_{t+1}} = \hat{a} + \hat{b}(t+1) = 2MA_t - MA'_t + \hat{b}, \quad \hat{b} = \frac{2}{m-1} (MA_t - MA'_t)$$

- 시점  $t$ 에서의  $l$  단계 이후 예측치

$$\widehat{F_{t+l}} = \hat{a} + \hat{b}(t+l) = (2MA_t - MA'_t) + \hat{b}l, \quad \hat{b} = \frac{2}{m-1} (MA_t - MA'_t)$$

- 시계열  $\{Z_n\}$ 에서, 시점  $t$ 에서의 관측값을  $Z_t$ 라 할 때, 시점  $n$ 에서의 **단순 이동평균**

$$: MA_n = \frac{Z_n + Z_{n-1} + \dots + Z_{n-m+1}}{m} = \frac{1}{m} \sum_{t=n-m+1}^n Z_t$$

- 시계열  $\{Z_n\}$ 에서, 시점  $t$ 에서의 관측값을  $Z_t$ 라 할 때, 시점  $n$ 에서의 **이중(선형) 이동평균**

$$: MA'_n = \frac{1}{m} (MA_n + MA_{n-1} + \dots + MA_{n-m+1})$$

## Unit 02 | 고전적 분석 - 평활법 & 분해법

### 이동평균법 (2) - 이중(선형) 이동평균법

표 3.4 가상자료에 대한 선형이동평균 예측

$t$	원계열( $Z_t$ )	이동평균( $MA_t$ )	이중이동평균( $MA'_t$ )	예측값( $F_t$ )	예측오차( $E_t$ )
1	10	—	—	—	—
2	18	—	—	—	—
3	20	16	—	—	—
4	28	22	—	—	—
5	30	26	21.33	—	—
6	38	32	26.67	35.34	2.66
7	37	35	31.00	42.66	-5.66

$$F_{5+1} = (2MA_5 - MA'_5) + \frac{2}{3-1}(MA_5 - MA'_5) \cdot 1 = 2 \times 26 - 21.33 + \frac{2}{3-1}(26 - 21.33) \cdot 1 = 35.34$$

$$F_{6+1} = (2MA_6 - MA'_6) + \frac{2}{3-1}(MA_6 - MA'_6) \cdot 1 = 2 \times 32 - 26.67 + \frac{2}{3-1}(32 - 26.67) \cdot 1 = 42.66$$

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (1) - 단순 지수평활법

- 지수평활법 : 모든 데이터 활용, 최근 관측치에 더 큰 가중치를 준 **가중평균** 값을 미래 시점의 예측치로 사용
- 시계열 구조 변화에 유연하게 대응 가능, 실제 활용 시 정확도가 높아 단기 예측에 많이 사용
- **단순 지수평활법** : 추세나 계절성이 없는, 수평적 패턴의 데이터에 유용
  - 시계열  $\{Z_n\}$ 의 시점  $n$ 에서의 지수평활치
    - :  $S_n = \alpha Z_n + \alpha(1 - \alpha)Z_{n-1} + \alpha(1 - \alpha)^2 Z_{n-2} + \dots$
  - 시계열  $\{Z_n\}$ 의 시점  $n + 1$ 에서의 지수평활치 :
    - :  $S_{n+1} = \alpha Z_{n+1} + (1 - \alpha)S_n$

## Notation

$Z_n$  : 시점  $n$ 에서의 관측값  
 $\alpha$  : 지수평활상수 (Smoothing Constant)

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (1) – 단순 지수평활법

- 지수평활상수  $\alpha$  선택

- MSE를 최소로 하는  $\alpha$  (일반적으로, 0.05 ~ 1)
- 1에 가까울수록 최근 추세 많이 반영, 변화에 민감하게 반응
- 0에 가까울수록 과거 데이터에도 영향 많이 받고, 전체 평균으로 예측

- 초기 평활값  $S_0$  선택

- Brown(1962), Montgomery & Johnson(1976) :  $\bar{Z} = \frac{1}{n} \sum_{t=1}^n Z_t$  (  $n = 6$  or  $n = \frac{T}{2}$  )
- Makridakis & Wheelwright(1978) :  $Z_1$



## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (2) – 이중 지수평활법

- 선형 추세가 있는 시계열에 단순 지수평활법을 적용하면, 추세를 늦게 따라가는 문제 발생
- **이중 지수평활법** : 지수평활을 두 번 적용, 시계열이 선형 추세가 있는 경우에 적합
  - 지수평활값과 이중지수평활값:
    - :  $SM_n = \alpha Z_n + (1 - \alpha)SM_{n-1}$  (지수평활값)
    - :  $SM'_n = \alpha SM_n + (1 - \alpha)SM'_{n-1}$  (이중지수평활값)

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (2) - 이중 지수평활법

- 시점  $t$  에서의 한 단계 이후  $t + 1$  시점의 예측치

$$F_{t+1} = E[Z_{t+1} | Z_t, Z_{t-1}, \dots, Z_1] = a + b(t + 1)$$

$$\widehat{F}_{t+1} = \hat{a} + \hat{b}(t + 1) = (2SM_t - SM'_t) + \hat{b}, \quad \hat{b} = \frac{\alpha}{1-\alpha} (SM_t - SM'_t)$$

- 시점  $t$  에서의  $l$  단계 이후 예측치

$$\widehat{F}_{t+l} = \hat{a} + \hat{b}(t + l) = (2SM_t - SM'_t) + \hat{b}l$$

## Unit 02 | 고전적 분석 - 평활법 & 분해법

### 지수평활법 (2) – 이중 지수평활법

- 지수평활상수  $\alpha = 0.2$ , 초기값  $SM_0 = Z_1 = 10$  일 때, 이중 지수평활법 기반 예측값


표 3.8 가상자료에 대한 브라운의 선형지수평활예측값

$t$	원계열( $Z_t$ )	지수평활값( $SM_t$ )	이중지수평활값( $SM_t$ )	예측값( $F_t$ )
1	10	10,000	10,000	$F_{1+1} = 2 \times 10 - 10 + \frac{0.2}{0.8} \times (10 - 10) = 10$
2	18	11,600	10,320	$F_{2+1} = 2 \times 11.60 - 10.32 + \frac{0.2}{0.8} \times (11.60 - 10.32) = 13.2$
3	20	13,280	10,912	$F_{3+1} = 2 \times 13.28 - 10.912 + \frac{0.2}{0.8} \times (13.28 - 10.912) = 16.24$
4	28	16,224	11,974	$F_{4+1} = 2 \times 16.224 - 11.794 + \frac{0.2}{0.8} \times (16.224 - 11.794) = 21.536$
5	30	18,379	13,255	$F_{5+1} = 2 \times 18.379 - 13.255 + \frac{0.2}{0.8} \times (18.379 - 13.255) = 24.78$
6	38	22,303	15,065	$F_{6+1} = 2 \times 22.303 - 15.065 + \frac{0.2}{0.8} \times (22.303 - 15.065) = 31.35$
7	37	25,242	17,101	


## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (3) – Holt-Winters 계절 지수평활법

- 월별, 분기별 자료 : **계절변동**(추세+계절성+수준(자료변동)) 존재
- **계절변동의 두 가지 형태**
  - 가법적 계절변동 : 시간에 따른 계절적 진폭의 크기 일정
  - 승법적 계절변동 : 계절적 진폭의 크기에 평균 수준에 비례하여 점차적으로 증가 or 감소



가법적 계절변동



승법적 계절변동

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (3) – Holt-Winters 계절 지수평활법

- **가법적 계절 지수평활법** : 가법적 계절변동이 있을 때, 가법적으로 각 성분(변동) 갱신
- 주기가  $p$  인 시계열  $\{y_t\}$  가 있다고 할 때, 갱신 알고리즘은 아래와 같다.

$$\hat{y}_{t+h|t} = \hat{\mu}_t + h \cdot b_t + s_{t+h-p}, \quad h \leq p$$

( $p$  : 계절성의 주기)

여기서  $\mu_t, b_t, s_t$ 는 시점  $t$ 에서 추정된 수준, 기울기, 계절효과를 의미한다.

$$\cdot \hat{\mu}_t = \alpha(y_t - s_{t-p}) + (1 - \alpha)(\hat{\mu}_{t-1} + b_{t-1})$$

$$\cdot b_t = \beta(\hat{\mu}_t - \hat{\mu}_{t-1}) + (1 - \beta)b_{t-1}$$

$$\cdot s_t = \gamma(y_t - \hat{\mu}_t) + (1 - \gamma)s_{t-p}$$

$$\cdot \alpha, \beta, \gamma : \text{전체, 추세, 계절조정을 위한 평활모수}$$

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 지수평활법 (3) – Holt-Winters 계절 지수평활법

- **승법적 계절 지수평활법** : 승법적 계절변동이 있을 때, 승법적으로 각 성분(변동) 갱신
- 주기가  $p$  인 시계열  $\{y_t\}$  가 있다고 할 때, 갱신 알고리즘은 아래와 같다.

$$\hat{y}_{t+h|t} = (\hat{\mu}_t + h \cdot b_t) \times s_{t+h-p}, \quad h \leq p$$

( $p$  : 계절성의 주기)

여기서  $\mu_t, b_t, s_t$ 의 의미는 위와 같으나, 수준과 계절효과의 세부적인 식이 다르다.

$$\cdot \hat{\mu}_t = \alpha \left( \frac{y_t}{s_{t-p}} \right) + (1 - \alpha)(\hat{\mu}_{t-1} + b_{t-1})$$

$$\cdot b_t = \beta(\hat{\mu}_t - \hat{\mu}_{t-1}) + (1 - \beta)b_{t-1}$$

$$\cdot s_t = \gamma \left( \frac{y_t}{\hat{\mu}_t} \right) + (1 - \gamma)s_{t-p}$$

·  $\alpha, \beta, \gamma$  : 전체, 추세, 계절조정을 위한 평활모수

## Unit 02 | 고전적 분석 - 평활법 & 분해법


### 지수평활법 (3) – Holt-Winters 계절 지수평활법

- 시계열  $\{Z_n\}$  에서의 시점이  $n$  인 경우,  $l$  시점 후의 예측값  $F_{n+l}$   
:  $F_{n+l} = (\mu_n + b_n \cdot l) \cdot s_{n+l-p}$
- 마찬가지로, 평활상수는 MSE를 최소화하는 값으로 선택한다.

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 분해법 (Decomposition Method)

- **분해법** : 시계열을 개별 변동성분(추세, 계절성, 순환성)으로 각각 분해한 후, 분해된 각 성분을 개별적으로 예측 → 이후 이를 다시 결합하여 예측
  - 오래된 예측법 중 하나, 최근에는 경제·경영 분야에서 다양하게 응용
  - **장점** : 직관적으로 이해하고 구현하기에 쉬움, 분해를 통해 변동의 원인 파악 가능
  - **단점** : 시계열에 이상점이 있는 경우 부적절





## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

## 대칭 이동평균 & 중심화 이동평균

- 시점  $t$  에서의 관측값을  $Z_t$  라 하고, 이동평균을  $MA_t$  라 하면,

- **대칭 이동평균** ( $m$ 이 홀수) : 해당 시점과 인접한 전후 시점들의 평균

$$: MA_t = \frac{1}{m} \sum_{j=-(m-1)/2}^{(m-1)/2} Z_{t+j}$$

- **중심화 이동평균** ( $m$ 이 짝수) : 짝수 기간의 이동평균은 두 시점 사이의 값에 대응  $\rightarrow$  재차 이동평균

$$: MA_t = \frac{1}{2} (MA_{t-\frac{1}{2}} + MA_{t+\frac{1}{2}})$$

$$MA_{t-1/2} = \frac{1}{m} \sum_{j=-m/2}^{m/2-1} Z_{t+j} \quad MA_{t+1/2} = \frac{1}{m} \sum_{j=-m/2+1}^{m/2} Z_{t+j}$$

## Unit 02 | 고전적 분석 - 평활법 & 분해법

# 대칭 이동평균 & 중심화 이동평균

가상적 자료에 대한 이동평균

출처: 시계열분석과 예측, 이누리 저, 제 2판 p77

기간	관측값 $\{Z_t\}$	3MA	관측값 $\{Z_t\}$	4MA	$2 \times 4MA$
1	20	—	20	—	—
2	10	20 $MA_2$	10	—	—
3	30	25 $MA_3$	30	23.75 $MA_{2.5}$	22.500 $MA_3$
4	35	25	35	21.25 $MA_{3.5}$	27.500
5	10	35	10	33.75	36.250
6	60	40	60	38.75	39.375
7	50	50	50	40.00	50.000
8	40	60	40	60.00	60.625
9	90	65	90	61.25	61.875
10	65	70	65	62.50	72.500
11	55	80	55	82.50	—
12	120	—	120	—	—

대칭 이동평균

중심화 이동평균

## Unit 02 | 고전적 분석 - 평활법 &amp; 분해법

$$\text{원 계열} - \text{추세} = \text{계절성} + \text{불규칙 성분}$$

## 분해법에 의한 예측 절차 (가법 모형 전제)

### 1. 추세 및 추세 조정된 계열의 추정

- ✓ 원 계열에 추세선을 적합시켜 추세를 추정 → 이 추세를 원 시계열에서 빼서 추세 조정된 계열 얻기

### 2. 계절성 및 계절 조정된 계열의 추정

- ✓ 추세 조정된 계열에 대하여 계절성의 길이만큼 이동평균 → 계절성 제거 (불규칙 변동만이 남음)
- ✓ 다시 추세 조정된 계열에서 추정된 불규칙 변동 제거 → 시점별 계절성 추정
- ✓ 이렇게 추정된 계절성별로 계절별 평균을 구하고, 계절평균의 합이 0이 되도록 조정 → 계절지수

### 3. 예측

- ✓ 분해된 성분들을 개별적으로 예측하여 원 계열의 미래값 예측

# Contents

---

Unit 01 | 시계열 데이터

---

Unit 02 | 고전적 분석 - 평활법 & 분해법

---

Unit 03 | 확률적 분석 - AR, MA, ARMA

---


Unit 04 | Box-Jenkins 방법론

---

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## 정상 시계열 (Stationary Time Series)


- **정상 시계열** : 시간에 관계없이 평균과 분산이 일정한 시계열
  - 모든  $t$  에 대해서  $E(Z_t) = \mu, \text{Var}(Z_t) = \sigma^2$
  - 두 시점 사이의 자기공분산은 시점  $t$  와 무관하며, 시차(time lag)  $k$  에만 의존  $\rightarrow$  시간 불변성
- **정상 시계열의 형태**
  - 추세, 계절성, 순환성 등의 패턴이 보이지 않음
  - 자료 변화의 폭이 일정함
  - 시간에 따라 달라지는 자기상관적 패턴을 나타내는 구간이 없음




## Unit 03 | 확률적 분석 - AR, MA, ARMA

## 정상 시계열, 비정상 시계열 예시

- **정상시계열** : 백색잡음과정 (White Noise)
  - ✓ 서로 독립이면서 동일한 분포를 따르는(i.i.d.) 확률변수들의 계열로 구성
  - ✓  $\{\varepsilon_t\} : \text{NW}(0, \sigma_\varepsilon^2), Z_t = \varepsilon_t$



- **비정상시계열** : 확률보행과정 (Random Walk)
  - ✓  $\{\varepsilon_t\} : \text{NW}(0, \sigma_\varepsilon^2), Z_t = Z_{t-1} + \varepsilon_t$
  - ✓ 평균은 0으로 일정하나, 분산이 시간에 종속



## Unit 03 | 확률적 분석 - AR, MA, ARMA

## 정상 시계열 여부 판단

- **판단 기준**
  - ✓ X축을 lag(현재 데이터와의 시점 차)로, Y축을 ACF(Autocorrelation Function)로 시각화
  - ✓ 특정 패턴이 없다면 정상 시계열, 있다면 비정상 시계열
- ✓ **[참고] Autocorrelation Function** (ACF, 자기상관함수)
  - ✓ Correlation(두 변수 간 관계를 -1~1 값으로 표현하는 척도)에 Auto 개념이 추가된 것
  - ✓ 시계열적 관점에서, time shifted된 자기 자신과의 correlation


## Unit 03 | 확률적 분석 - AR, MA, ARMA

## ACF &amp; PACF

## • ACF (자기상관함수)


- ✓ 시차 k 에 대해서, 관측치 간 상관계수 함수

$$ACF(k) = \frac{\sum_{t=1}^{N-k} (y_t - \bar{y})(y_{t+k} - \bar{y})}{\sum_{t=1}^N (y_t - \bar{y})^2}$$



## • PACF (Partial ACF, 편자기상관함수)

- ✓ 시차 k 에 대해서,  $Z_t$ 와  $Z_{t+k}$  사이에 있는 관측치와의 상호 의존성을 제거한 함수
- ✓ 순수한 상관관계 파악 가능





## Unit 03 | 확률적 분석 - AR, MA, ARMA

## Box-Jenkins 세 가지 모형

- 자기회귀모형 (Auto Regressive) : AR(p) 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} + a_t, \quad a_t \text{는 iid인 white noise}$$

- 이동평균모형 (Moving Average) : MA(q) 모형

$$Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q}, \quad a_t \text{는 iid인 white noise}$$

- 자기회귀이동평균 모형 (Auto Regressive Moving Average) : ARMA(p, q) 모형

$$\begin{aligned} Z_t = & \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} \\ & + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q} \end{aligned}$$

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## Box-Jenkins 모형 (1) – AR(p) 모형

자기회귀모형 (Auto Regressive) : AR(p) 모형



$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} + a_t, \quad a_t \text{는 iid인 white noise}$$

- 자기 자신을 종속변수로 하고, 그 이전 시점의 시계열을 독립변수로 하는 모형
  - 즉, 시계열  $Z_t$  를 그 이전 시점의 계열로 회귀
  - p차 AR 모형은  $Z_t$  가  $Z_{t-1}, Z_{t-2}, \dots, Z_{t-p}$  의 선형결합임을 가정, **항상 가역성 만족**
- p는 하이퍼파라미터 (ACF, PACF 확인 후 결정)
- 회귀모형과 달리,
  - ✓ 독립변수 간 독립성 가정 없음
  - ✓ 독립변수 개수가 모형의 추정 과정에서 결정

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## AR(p) 예시 : AR(1), AR(2)



$$\text{AR}(1) : Z_t = \phi_1 Z_{t-1} + a_t$$



자기회귀모형 (Auto Regressive) : AR(p) 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} + a_t, \quad a_t \text{는 iid인 white noise}$$

$$\text{AR}(2) : Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + a_t$$



## Unit 03 | 확률적 분석 - AR, MA, ARMA

## Box-Jenkins 모형 (2) – MA(q) 모형

이동평균모형 (Moving Average) : MA(q) 모형



$$Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q}, \quad a_t \text{는 iid인 white noise}$$

- 자기 자신을 종속변수로 하고, 그 이전 시점의 white noise process를 독립변수로 하는 모형
  - 즉, 시계열  $Z_t$  를 그 이전 시점의 백색잡음 계열  $\{a_t, a_{t-1}, a_{t-2}, \dots\}$ 로 회귀
  - q차 MA 모형은 **항상 정상성 만족**
- q는 하이퍼파라미터 (ACF, PACF 확인 후 결정)

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## MA(q) 예시 : MA(1), MA(2)



$$\text{MA}(1) : Z_t = a_t - \theta_1 a_{t-1}$$



이동평균모형 (Moving Average) : MA(q) 모형

$$Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q}, \quad a_t \text{는 iid인 white noise}$$

$$\text{MA}(2) : Z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}$$



## Unit 03 | 확률적 분석 - AR, MA, ARMA

## AR(p) 모형, MA(q) 모형 비교

- AR(p), MA(q) 모형의 Theoretical ACF, PACF 특징

	AR(p)	MA(q)
ACF	<b>Die out</b> (지수적 감소, 소멸하는 sine 함수 형태)	<b>Cut off after lag q</b> (q+1 시점부터 0으로 절단)
PACF	<b>Cut off after lag p</b> (p+1 시점부터 0으로 절단)	<b>Die out</b> (지수적 감소, 소멸하는 sine 함수 형태)

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## Box-Jenkins 모형 (3) – ARMA(p, q) 모형

자기회귀이동평균 모형 (Auto Regressive Moving Average) : ARMA(p, q) 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} \\ + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q}$$



- ARMA(p, q) 모형은 AR(p) 모형과 MA(q) 모형을 결합시킨 모형
- 정상성과 가역성을 만족하기 위해서는,
  - ✓ AR 부분 특성 방정식의 모든 근의 절댓값이 1보다 커야 함 → 정상성 만족
  - ✓ MA 부분 특성 방정식의 모든 근의 절댓값이 1보다 커야 함 → 가역성 만족
- p, q는 하이퍼파라미터 (ACF, PACF 확인 후 결정)

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## ARMA(p, q) 모형 예시 : ARMA(1, 1)

자기회귀이동평균 모형 (Auto Regressive Moving Average) : ARMA(p, q) 모형

$$Z_t = \phi_1 Z_{t-1} + \phi_2 Z_{t-2} + \phi_3 Z_{t-3} + \cdots + \phi_p Z_{t-p} \\ + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \theta_3 a_{t-3} - \cdots - \theta_q a_{t-q}$$



- ARMA(1,1) 모형의 ACF와 PACF
  - ACF : AR 모형의 ACF처럼 Die out(지수적 감소)
  - PACF : MA 모형의 PACF처럼 Die out(지수적 감소)



## Unit 03 | 확률적 분석 - AR, MA, ARMA

## AR(p) 모형, MA(q), ARMA(p, q) 모형 비교

- AR(p), MA(q), ARMA(p, q) 모형의 Theoretical ACF, PACF 특징

	AR(p)	MA(q)	ARMA(p, q)
ACF	<b>Die out</b> (지수적 감소, 소멸하는 sine 함수 형태)	<b>Cut off after lag q</b> (q+1 시점부터 0으로 절단)	<b>Die out</b> (q-p+1 시점부터 지수적 감소, 소멸하는 sine 함수 형태)
PACF	<b>Cut off after lag p</b> (p+1 시점부터 0으로 절단)	<b>Die out</b> (지수적 감소, 소멸하는 sine 함수 형태)	<b>Die out</b> (p-q+1 시점부터 지수적 감소, 소멸하는 sine 함수 형태)

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## 비정상 시계열 - ARIMA(p, d, q) 모형

- 추세나 계절성이 포함된 비정상 시계열의 경우, 해당 시계열을 **차분**을 통해 정상화할 수 있음
  - 즉, **차분을 통해 추세나 계절성을 제거(감소)**할 수 있음
- 참고) 비정상성 판단
  - ✓ Augmented Dickey-Fuller Test
  - ✓ 검정통계량 값(ADF)이 임계값보다 작으면(p-value가 신뢰수준보다 작으면) stationary
  - ✓ [Python] `from statsmodels.tsa.stattools import adfuller`

## Unit 03 | 확률적 분석 - AR, MA, ARMA


## 비정상 시계열 - ARIMA(p, d, q) 모형

- 차분(Differencing) : 현 시점 데이터에서, d 시점 이전 데이터를 뺀 것
- 차분을 통해 시계열을 정상화할 수 있는데, 과대차분은 ACF를 복잡하게 만들거나 분산을 크게 함

X		
2	X	Y
7	2	5
10	7	3
5	10	-5
8	5	3
	8	-

1차 차분:  $Y_t = X_t - X_{t-1} = \nabla X_t$ 

X		
2		
7	X	Y
10	2	8
5	7	-2
8	10	-2
	5	-
	8	-

2차 차분:  $Y_t^{(2)} = X_t - X_{t-2} = \nabla^{(2)} X_t$ 

## Unit 03 | 확률적 분석 - AR, MA, ARMA

## 비정상 시계열 - ARIMA(p, d, q) 모형

- ARIMA(p, d, q) : 누적(Integrated) 자기회귀이동평균 모형
  - ✓ d차 차분으로 변환된 시계열이 ARMA(p, q)를 따르면, 원 시계열은 ARIMA(p, d, q)를 따른다.
- p, d, q는 하이퍼파라미터
- 참고) 계절성 시계열 데이터
  - ✓ 계절성이 있는 시계열 데이터는 비정상
  - ✓ 단순 차분을 반복하여 적용함으로써 정상 시계열로 전환되기도 하나, 과대차분의 위험
  - ✓ 일반적으로 계절 차분이 효과적  $\rightarrow Z_t \sim \text{SARIMA}(p, d, q) \times (P, D, Q)_s$

## Unit 03 | 확률적 분석 - AR, MA, ARMA

튜토리얼 : <https://hyperconnect.github.io/2020/03/09/prophet-package.html>

### 참고) 시계열 예측 패키지 Prophet

- Prophet : 페이스북에서 공개한 시계열 예측 라이브러리
  - ✓ 정확도가 높고 빠름
  - ✓ 직관적인 파라미터 → 모델 수정에 용이
- 모델의 주요 구성 요소 : Trend, Seasonality, Holiday
  - $y(t) = g(t) + s(t) + h(t) + \epsilon_i$ 
    - $g(t)$  : Trend. 부분적으로 선형 or 로지스틱 곡선으로 구성.
    - $s(t)$  : Seasonality. Trend와 달리 주기적으로 나타나는 패턴 포함.
    - $h(t)$  : Holiday. 휴일과 같이 불규칙한 이벤트 나타냄.

# Contents

---

Unit 01 | 시계열 데이터

---

Unit 02 | 고전적 분석 - 평활법 & 분해법

---

Unit 03 | 확률적 분석 - AR, MA, ARMA

---

Unit 04 | Box-Jenkins 방법론

---

## Unit 04 | Box-Jenkins 방법론

# Box-Jenkins 방법론

### 모형 식별

- 시계열 자료를 보고 잠정적인 ARIMA 모형 찾기
- 모수 절약의 원칙 : 가급적 모수는 적게! (AIC, BIC)

### 모수 추정

- 최소제곱법 (AR 모형), 비선형 최소제곱법
- 최대우도추정법

### 모형 적합성 진단

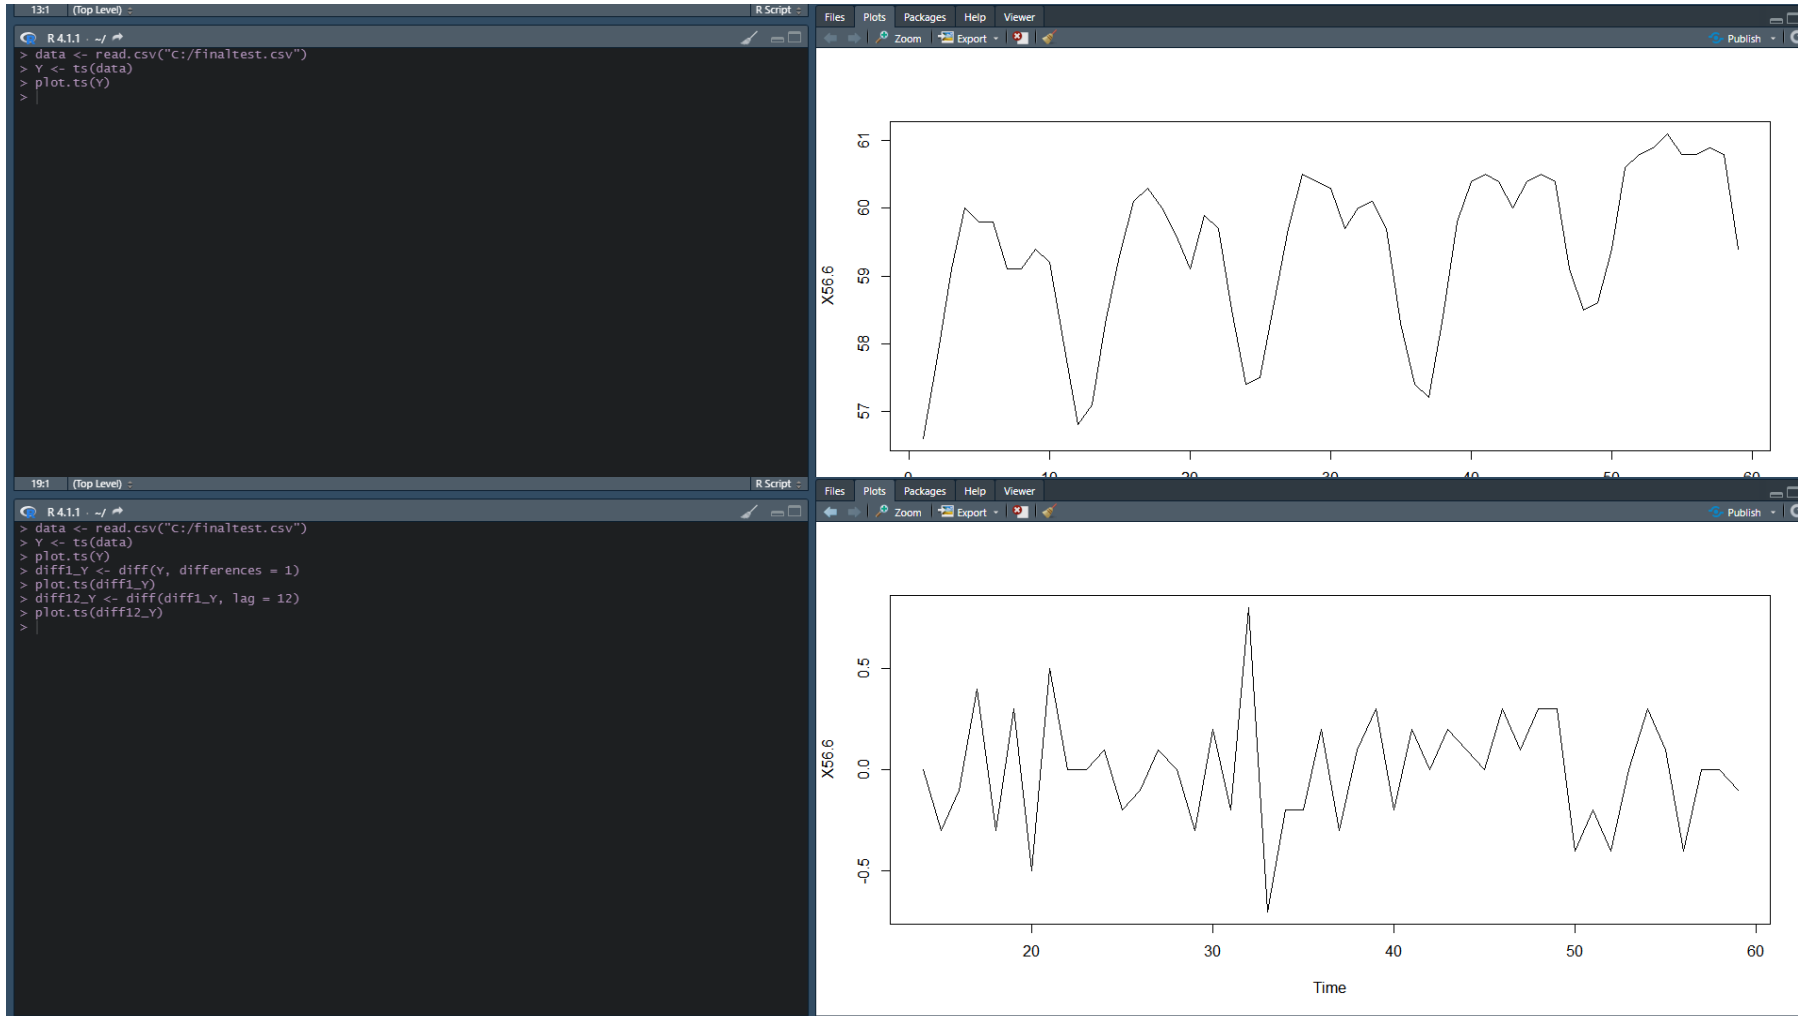
- 모형의 오차항에 대한 가정 검토
- 잔차의 정규성, 등분산성 및 패턴 유무, 랜덤성 (포트만토 검정)

### 모형 확정 및 예측

- 예측값 구하기

## Unit 04 | Box-Jenkins 방법론

## Box-Jenkins 방법론 실습 - 1. 모형 식별

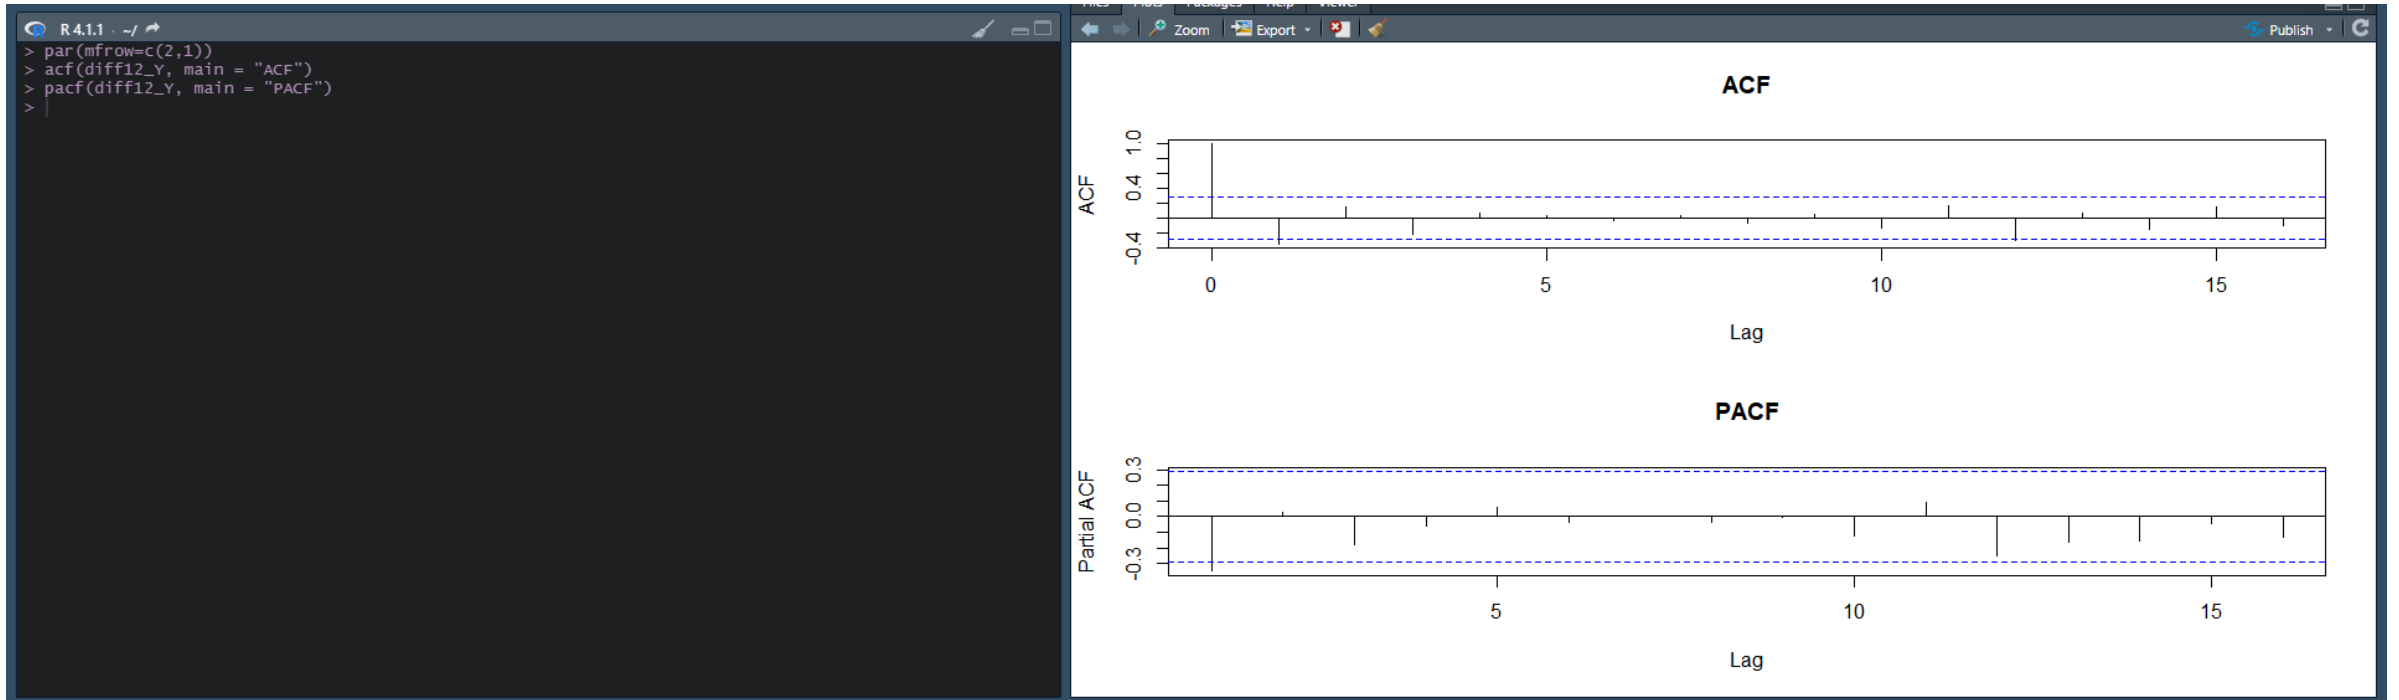


- csv 파일을 불러와 시도표 확인(plot.ts)
- 분산은 일정한 것으로 보임
- 추세 및 계절성이 있다고 판단 : 차분을 수행하되, 1차 차분(differences=1) 및 계절 차분(lag=12)을 순서대로 진행
- 만들어진 정상 시계열이 'diff12\_Y'



## Unit 04 | Box-Jenkins 방법론

## Box-Jenkins 방법론 실습 - 1. 모형 식별



- 'diff12\_Y'의 ACF와 PACF를 확인한 후, 3가지 후보 모형 선정

- 1) SARIMA(1, 1, 1) X (1, 1, 0) : 'fit1'
- 2) SARIMA(0, 1, 1) X (1, 1, 0) : 'fit2'
- 3) SARIMA(2, 1, 1) X (1, 1, 0) (auto.arima 결과 활용) : 'fit3'

## Unit 04 | Box-Jenkins 방법론

## Box-Jenkins 방법론 실습 - 2. 모수 추정

```
> fit1

Call:
arima(x = Y, order = c(1, 1, 1), seasonal = list(order = c(1, 1, 0), period = 12))

Coefficients:
      ar1      ma1      sar1
    0.6091 -0.9513 -0.4285
s.e.  0.3824  0.3755  0.1818

sigma^2 estimated as 0.05561:  log likelihood = -0.78,  aic = 9.56
> fit2

Call:
arima(x = Y, order = c(0, 1, 1), seasonal = list(order = c(1, 1, 0), period = 12))

Coefficients:
      ma1      sar1
   -0.4187 -0.4305
s.e.  0.1580  0.1507

sigma^2 estimated as 0.05759:  log likelihood = -0.94,  aic = 7.89
> fit3

Call:
arima(x = Y, order = c(2, 1, 1), seasonal = list(order = c(1, 1, 0), period = 12))

Coefficients:
      ar1      ar2      ma1      sar1
    0.5279  0.1951 -1.0000 -0.3968
s.e.  0.1459  0.1472  0.0969  0.1520

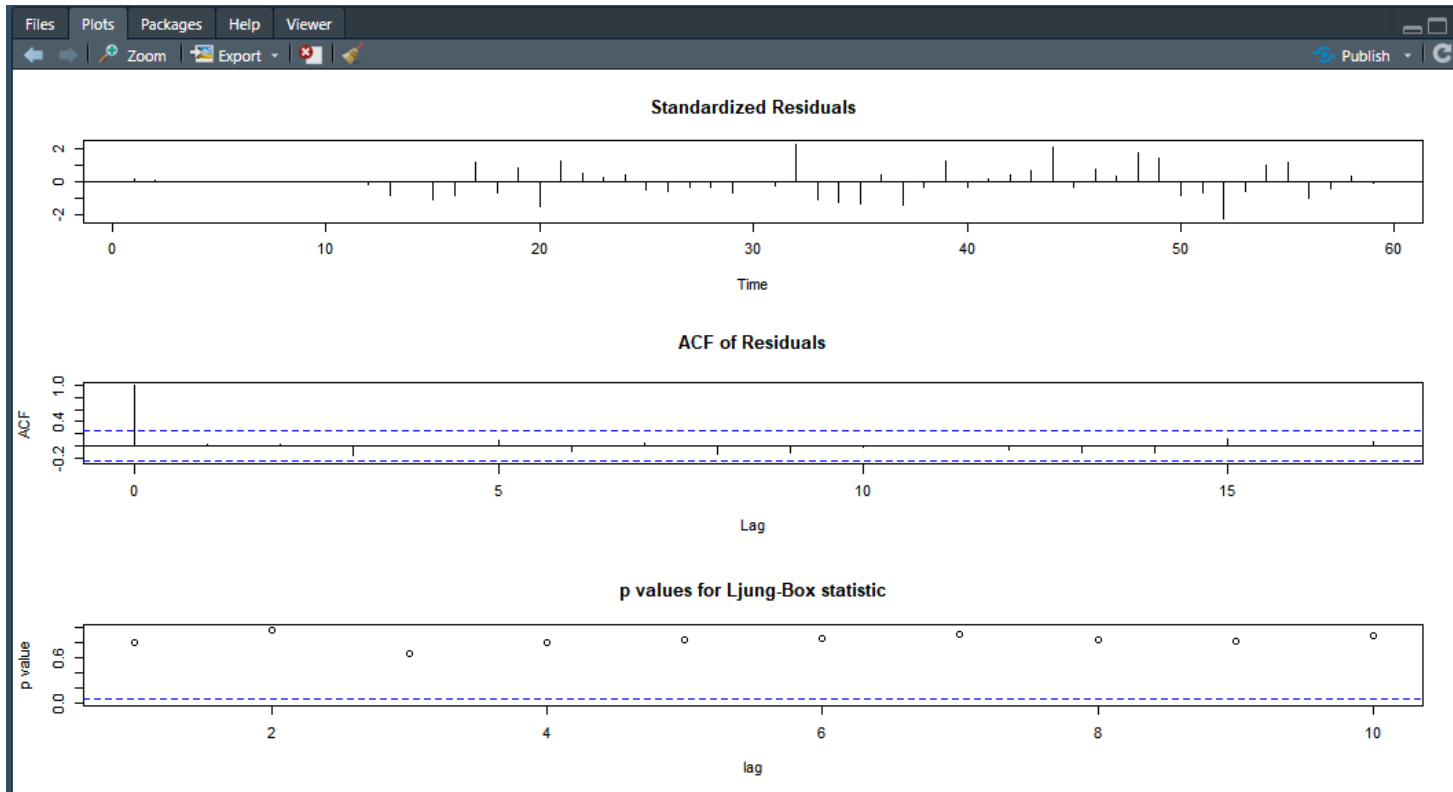
sigma^2 estimated as 0.05278:  log likelihood = 0.09,  aic = 9.83
>
```

- 1) SARIMA(1, 1, 1) X (1, 1, 0) : 'fit1'
- 2) SARIMA(0, 1, 1) X (1, 1, 0) : 'fit2'
- 3) SARIMA(2, 1, 1) X (1, 1, 0)  
(auto.arima 결과 활용) : 'fit3'

3가지 후보 모형을 비교해본 결과,  
'fit2'에 대한 AIC 값이 가장 작게 나왔음.  
따라서 최종 모형은  
SARIMA(0, 1, 1) X (1, 1, 0)으로 결정!

## Unit 04 | Box-Jenkins 방법론

## Box-Jenkins 방법론 실습 - 3. 모형 적합성 진단



- `tsdiag(fit2)`의 실행 결과
- 모형이 잘 나온 것으로 보이는데,
  - ✓ 잔차의 ACF에서 자기상관성이 눈에 띄지 않고,
  - ✓ p value가 기준선 위에 위치하기 (높게 나왔기) 때문

## Unit 04 | Box-Jenkins 방법론


## Box-Jenkins 방법론 실습 - 4. 모형 확정 및 예측

```
> diff12_Y.forecasts <- forecast(fit2, h = 12)
> diff12_Y.forecasts
```

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
60	58.67934	58.37181	58.98687	58.20901	59.14967	
61	58.65019	58.29447	59.00591	58.10617	59.19421	
62	59.62239	59.22428	60.02050	59.01353	60.23125	
63	60.90849	60.47208	61.34490	60.24106	61.57592	
64	61.28069	60.80909	61.75229	60.55944	62.00195	
65	61.38069	60.87634	61.88504	60.60936	62.15203	
66	61.45154	60.91645	61.98664	60.63318	62.26990	
67	61.10849	60.54432	61.67266	60.24567	61.97131	
68	61.28069	60.68888	61.87250	60.37559	62.18579	
69	61.38069	60.76247	61.99891	60.43520	62.32618	
70	61.28069	60.63714	61.92424	60.29646	62.26492	
71	59.92374	59.25582	60.59166	58.90225	60.94524	

- fit2에 기반한 예측값 12개
- **forecast** 함수를 활용하여 신뢰구간 80%, 95%의 상한과 하한도 함께 출력

Forecasts from ARIMA(0,1,1)(1,1,0)[12]



## 과제

### [과제] 시계열 분석 실습

- 데이터 : 'kingage.csv'
  - ✓ 출처 : <http://robjhyndman.com/tsdldata/misc/kings.dat>
- Box-Jenkins 방법론(모형 식별, 모수 추정, 모형 적합성 진단, 모형 확정 및 예측)에 따라 시계열 분석을 진행해주세요!
  - ✓ 각 단계별 설명을 주석으로 달아주시면 감사하겠습니다 :)
  - ✓ 최종적으로, **예측값 17개를 출력**해주세요.
- Python, R 중 어느 것을 사용하셔도 무관합니다.

## Reference

## [강의안]

- 투빅스 14기 이원도님 강의안
- 연세대학교 응용통계학과 문지은 교수님 <시계열분석> 강의안

**[교재]**

- Robert H. Shumway, David S. Stoffer, <Time Series Analysis and Its Applications>

## [참고 자료]

- [시계열 분해] [Chapter 6 시계열 분해 | Forecasting: Principles and Practice \(otexts.com\)](#)
- [AR, MA, ARMA] [\[머신러닝\]\[시계열\] AR, MA, ARMA, ARIMA의 모든 것 - 개념편 \(velog.io\)](#)
- [ARIMA] [ARIMA, Python으로 하는 시계열분석 \(feat. 비트코인 가격예측\) \(byeongkijeong.github.io\)](#)
- [Prophet] <https://hyperconnect.github.io/2020/03/09/prophet-package.html>

Q & A

들어주셔서 감사합니다.